

ปัญญาประดิษฐ์ (Artificial Intelligence: AI)

บทที่ 8 : การประมวลผลภาษาธรรมชาติ (Natural Language Processing)

โดย อาจารย์ ดร.กริชบดินทร์ ผิวหอม



KNN

ตารางที่ 1. กำหนดให้มีการจำแนกสัตว์ 5 ชนิด ตามคุณสมบัติที่สามารถบ่งบอกถึงสายพันธุ์ดังนี้

	ออกลูก เป็นตัว	ออกลูก เป็นไข่	เลี้ยงลูก ด้วยน้ำนม	มีขนตาม ร่างกาย	ผิวหนัง หรือมีเกล็ด	สัตว์ เลือดอุ่น	สัตว์ เลือดเย็น	อยู่ทั้ง ในน้ำ และ บนบก	หายใจ ด้วย เหงือก	สายพันธุ์
กบ		✓					✓	✓		สัตว์ครึ่งบกครึ่งน้ำ
เปิด		✓		✓		✓		✓		สัตว์จำพวกนก
ค่างคาว	✓		✓	✓						สัตว์เลี้ยงลูกด้วยนม
งู		✓			✓		✓			สัตว์เลื้อยคลาน
ปลา		✓			✓		✓		✓	สัตว์จำพวกปลา

หัวข้อ (Outline)

- การประมวลผลภาษาธรรมชาติ (Natural Language Processing: NLP)



ข้าพเจ้าไม่ได้ล้มเหลว...

ข้าพเจ้าแค่ค้นพบ 10,000 วิธี

ที่มัน "ไม่ได้ผล"

Thomas Alva Edison






Image Source :

http://zenashapter.com/blog/wp-content/uploads/2014/05/20090326_085025_OP27keefedpo.jpg

การประมวลผลภาษาธรรมชาติ

ภาษาธรรมชาติคืออะไร

BSL Fingerspelling Alphabet




Source: <http://choicecentral.blogspot.com>


Understand the meaning of your baby's cries



Source: <http://lilsugar.com>



Source: <http://amazon.co.uk>



Natural Language Processing: NLP

- ภาษา คือ สื่อกลางการติดต่อสื่อสารระหว่างมนุษย์ที่เข้าใจง่ายที่สุด แต่ละภาษามีรูปแบบแตกต่างกัน
- ภาษามนุษยชาติ คือ ภาษาพื้นฐานในการติดต่อสื่อสารของมนุษย์
- การประมวลผลภาษามนุษยชาติ คือ กระบวนการที่จะช่วยให้เครื่องคอมพิวเตอร์สามารถเข้าใจความหมายและตีความภาษามนุษยชาติของมนุษย์ได้

Formal Language

คือ ภาษาที่มีแบบแผนชัดเจน แน่นนอน หรือเป็นสูตรที่ใช้ในกระบวนการทางคอมพิวเตอร์ และเครื่องจักรกล

ประกอบด้วยส่วนสำคัญ

1. **ชุดคำ** (String) การจัดเรียงกันตามรูปแบบของไวยากรณ์ในภาษานั้นๆ เช่น “ $P \vee Q$ ” = ชุดคำ 1 ชุด ซึ่งมีความหมาย แต่ถ้าเรียงผิด เช่น “ $P Q \vee$ ” ก็จะผิดไวยากรณ์ของภาษานั้นๆ
2. **สัญลักษณ์** (Symbol) เป็นส่วนประกอบของคำ ตัวแปร หรือเครื่องหมายภายในประโยค โดยจะนำมารวมกันจนได้ ชุดคำ ที่ต้องการ เช่น “ $\vee$ ” “ $\wedge$ ”
3. **ไวยากรณ์** (Grammar) ใช้จัดระเบียบหรือกำหนดกฎในการจัดเรียงคำต่างๆ ในประโยค เพื่อให้เกิดความเข้าใจที่ชัดเจนและถูกต้อง
4. **ความหมาย** (Semantic) ประโยคหรือคำ ในทุกภาษาต้องมีความหมาย

การวิเคราะห์ไวยากรณ์ (Syntactic Analysis)

เป็นการพิจารณาประโยค เพื่อดูโครงสร้างและคำต่างๆ ในประโยคว่ามีความสัมพันธ์กันอย่างไร มีส่วนประกอบสำคัญ 2 ส่วน

- ไวยากรณ์ (Grammar) เสมือนการตั้งกฎเพื่่อ้างอิงรูปแบบของโครงสร้างในประโยค ส่วนมากจะใช้รูปแบบของไวยากรณ์ไม่พึ่งบริบท (Context-free Grammars)
- Parser คือ การวิเคราะห์คำในไวยากรณ์ ส่วนใหญ่จะอยู่ในรูปของโครงสร้างการแจกแจงแบบต้นไม้ (Parser Tree)

Context-free Grammars (CFG)

คนกินข้าว

สวัสดีครับ

Context-free Grammars (CFG)

- $S \rightarrow 01$
- $S \rightarrow 0S1$

Context-free Grammars (CFG)

ส่วนประกอบของ CFG

1. Terminal = {0,1}
2. Variable = {S,A}
3. Start symbol = S
4. Production (กฎเกณฑ์)
 - $S \rightarrow AS$
 - $A \rightarrow 0S$
 - $S \rightarrow 1$

คำอธิบาย

- Terminal ตัวอักษรที่แทนสัญลักษณ์ของภาษา เช่น a, b, 0, 1, 2,...
- Variable/Nonterminal ชุดของสัญลักษณ์ภาษา เช่น A, B, S,...
- Rules กลุ่มของกฎ
- Start symbol ตัวเริ่มต้นภาษาแทนด้วย Nonterminal

Context-free Grammars (CFG)

ส่วนประกอบของ CFG

1. Terminal = {0,1}
2. Variable = {S}
3. Start symbol = S
4. Production (กฎเกณฑ์)
 - $S \rightarrow 1S$
 - $S \rightarrow 0S$
 - $S \rightarrow 1$

จงตรวจสอบสตริง 001 และ 100 ว่า
รองรับกฎ(Accept)หรือไม่รองรับ
(Reject)?

วิธีทำ

001; $S \Rightarrow 0S \Rightarrow 00S \Rightarrow 001$
Accept

100; $S \Rightarrow 1S \Rightarrow 10S \Rightarrow 101$
Reject

แบบทดสอบที่ 1

จากกฎของไวยากรณ์

$S \rightarrow 0S$

$S \rightarrow 1S$

$S \rightarrow 1$

จงตรวจสอบสตริงดังต่อไปนี้

ต่อไปนี้ตามขั้นตอน ว่า

Accept / Reject

1. 0

2. 1

3. 01

4. 10

5. 11

6. 010101

แบบทดสอบที่ 2

จากกฎของไวยากรณ์

$S \rightarrow 0A1 \mid 1B0$

$A \rightarrow 1S \mid 0B \mid 11 \mid 1$

$B \rightarrow S1 \mid A0 \mid 00 \mid 0$

จงตรวจสอบสตริงดังต่อไปนี้

ต่อไปนี้ตามขั้นตอน ว่า

Accept / Reject

1. 011

2. 110

3. 0110001

4. 1000110

5. 1111110

Parser Tree

- พาร์เซอร์ คือ การตรวจสอบและการแสดงความสัมพันธ์แต่ละประโยค หลังจากผ่านการวิเคราะห์โครงสร้างของไวยากรณ์แล้ว ส่วนมากจะนำเสนอในรูปแบบ “ต้นไม้”
- ประกอบด้วย
 - ราก (Root) โหนดเริ่มต้นแทนด้วย S
 - ใบ (Leaf) คำศัพท์หรือหน้าที่ของคำ
 - กิ่งก้าน (Branch) เชื่อมระหว่างรากและใบ หรือ ใบและใบ

Parser Tree


จงตรวจสอบสตริง 001 และ
100 ในรูปแบบโครงสร้าง
ต้นไม้ (Parser tree)

วิธีทำ

จาก 100; $S \Rightarrow 1S \Rightarrow 10S \Rightarrow 101$

?

จาก 001; $S \Rightarrow 0S \Rightarrow 00S \Rightarrow 001$



แบบทดสอบที่ 3

จากกฎของไวยากรณ์

$S \rightarrow 0A1 \mid 1B0$

$A \rightarrow 1S \mid 0B \mid 11 \mid 1$

$B \rightarrow S1 \mid A0 \mid 00 \mid 0$

จงตรวจสอบสตริงดังต่อไปนี้
ในรูปแบบโครงสร้าง
ต้นไม้ (Parser tree)

1. 011

2. 110

3. 0110001

4. 1000110

5. 1111110

Summary

การประมวลผลภาษาธรรมชาติ คือ กระบวนการที่ช่วยให้เครื่องคอมพิวเตอร์เข้าใจความหมายภาษามนุษย์ได้ โดยผ่านกระบวนการต่างๆ ในการพัฒนาระบบ NLP จึงต้องศึกษาลักษณะโครงสร้างของภาษาเพื่อช่วยให้เครื่องคอมพิวเตอร์เข้าใจรูปแบบการสื่อสาร